Análisis FinOps: Modelo API-First vs. Suscripciones SaaS

Plataforma: Lulo Studio — Marketing AI Studio
Fecha de corte de precios: 10 de octubre de 2026
Moneda: USD, precios sin impuestos
Audiencia: stakeholders y planificación financiera interna

Resumen ejecutivo

Lulo Studio consume IA generativa (texto, voz, video con avatar e imagen) a través de APIs de pago por uso, orquestadas desde una interfaz propia. Este documento compara ese modelo con la alternativa de pagar las suscripciones "Pro / Business" de cada herramienta para un equipo de 3 personas.

Escenario mensual	Stack SaaS (3 usuarios)	Stack API-First	Ahorro	%
Mes sin producción	$348.50	$6.00	$342.50	**98 %**
Mes bajo (20 videos, 100 audios)	$348.50	$47.92	$300.58	**86 %**
Mes base (100 videos, 500 audios)	**$425.50**	**$215.62**	**$209.88**	**49 %**
Mes pico (300 videos, 1,500 audios)	$700.50	$634.86	$65.64	**9 %**
Año mixto (4 bajos + 6 base + 2 picos)	**$5,348**	**$2,755**	**$2,593**	**48 %**

Conclusiones clave:

1. En un mes típico, el modelo API-First **cuesta la mitad** que el stack SaaS equivalente, y casi nada en meses de baja actividad.
2. La ventaja es mayor cuanto más varía la demanda: el SaaS cobra la capacidad que se *reserva*; la API cobra lo que se *consume*.
3. Hay un punto donde el SaaS se acerca: **el video con avatar en volumen alto** (ver §4). Lo tratamos con transparencia porque define la estrategia de optimización.
4. El ahorro en dinero es solo una parte. La automatización del flujo ahorra **~35 horas-persona al mes** en el escenario base (§3.4), lo que el SaaS no puede ofrecer.

1. Desglose de costos oficiales por API (pago por uso)

1.1 Modelos de lenguaje (LLM) vía OpenRouter

Usos en Lulo Studio: guiones (`/api/openrouter/script`), copiloto "Mia", auditor de campañas "Busi".

Modelo	Entrada / 1M tokens	Salida / 1M tokens	Entrada / 1K	Salida / 1K	Uso recomendado
Claude Haiku 5.5	$0.10	$0.50	$0.0001	$0.0005	Clasificación, borradores, ganchos A/B masivos
Gemini 3.8 Flash	$0.75	$3.75	$0.00075	$0.00375	Copiloto Mia, guiones rápidos
Gemini 3.1 Flash Lite	$0.25	$1.50	$0.00025	$0.0015	Tareas de alto volumen y bajo valor
Claude Sonnet 5.5	$2.00	$10.00	$0.002	$0.010	Guiones finales de venta
Gemini 3.1 Pro (preview)	$2.00	$12.00	$0.002	$0.012	Análisis largos
Claude Opus 5.5	$4.00	$20.00	$0.004	$0.020	Estrategia y auditorías complejas

> Las variantes *batch* de Claude y Gemini cuestan **50 % menos**, útiles para procesos nocturnos como generar 50 variantes de gancho.

Costo unitario real en nuestro flujo:

Operación	Supuesto de tokens	Modelo	Costo por operación
Guion de video de 30 s	3K entrada + 1.5K salida	Sonnet 5.5	**$0.021**
Mismo guion	3K + 1.5K	Haiku 5.5	$0.001
Mensaje del copiloto Mia	4K entrada + 0.8K salida	Gemini 3.8 Flash	**$0.006**
Auditoría de campaña (Busi)	20K entrada + 3K salida	Sonnet 5.5	**$0.07**

1.2 Texto a voz (ElevenLabs)

Modelo	Canal	Costo / 1,000 caracteres	Costo / minuto de audio*
Eleven v4	**OpenRouter**	**$0.040**	~$0.036
Eleven v4 Turbo	OpenRouter	$0.020	~$0.018
Multilingual v2	ElevenLabs API directa	$0.080	~$0.072
Eleven v3	ElevenLabs API directa	$0.080	~$0.072
Flash / Turbo	ElevenLabs API directa	$0.040	~$0.036

* Supuesto: ~900 caracteres por minuto de locución en español (~150 palabras/min).

- **Audio de 30 s (~450 caracteres) con v4 vía OpenRouter: $0.018.**

- **Clonación de voz (IVC):** requiere como mínimo el plan **Starter de ElevenLabs ($6/mes)**. Es el único costo fijo de nuestro stack y está incluido en todos los cálculos.
- **Hallazgo de optimización:** v4 vía OpenRouter cuesta **la mitad** que Multilingual v2 en la API directa. Conviene migrar el TTS por defecto.

1.3 Video con avatar (HeyGen Avatar IV)

Canal	Costo / segundo	Costo / minuto	Video de 30 s
OpenRouter `heygen/avatar-iv` (nuestra ruta actual)	**$0.05**	**$3.00**	**$1.50**
API directa de HeyGen (pay-as-you-go)	$0.10	$6.00	$3.00
Creación de Photo Avatar / Digital Twin (API directa)	$1 por avatar, único	—	—

- La API directa de HeyGen funciona con monedero prepago desde $5, sin suscripción y con 10 trabajos concurrentes.
- **Hallazgo:** enrutar por OpenRouter cuesta **50 % menos** que la API directa de HeyGen. El cliente legacy `services/heygen.service.ts` y el flujo UGC (que todavía llama a `/api/heygen/generate`) deberían migrarse a OpenRouter.

Modelos de video complementarios (catálogo `ugc-models.config.ts`, sincronizado con precios en vivo):

Modelo	Proveedor	$/s	Clip de 5 s	Uso
Seedance 1.5 Pro	OpenRouter	$0.023	$0.12	Ganchos y pruebas A/B baratas
Wan 2.6	OpenRouter	$0.040	$0.20	B-roll de producto
Seedance 2.0 Fast	OpenRouter	$0.040	$0.20	Creador sintético recurrente
MiniMax Hailuo 2.3	APIMart	$0.049	$0.24	Testimonios realistas
Seedance 2.0	APIMart	$0.066	$0.33	UGC vertical
Kling v3 Omni	APIMart	$0.067	$0.34	Interacción con producto

1.4 Generación de imágenes, Canva y Busi

Recurso	Canal	Precio oficial	Costo estimado por imagen*
Nano Banana (Gemini 2.5 Flash Image)	OpenRouter	$30 / 1M tokens de salida	~$0.039
Nano Banana 2 Lite	OpenRouter	$30 / 1M tokens de salida	~$0.039
Nano Banana 2 (Gemini 3.1 Flash Image)	OpenRouter	$60 / 1M tokens de salida	**~$0.077**
Nano Banana Pro (Gemini 3 Pro Image)	OpenRouter	$120 / 1M tokens de salida	~$0.155

* Estimado con ~1,290 tokens de salida por imagen de ~1024 px. OpenRouter factura por token, así que el costo real varía con la resolución.

- **Canva:** la Connect API no tiene tarifa por llamada. Sin embargo, las funciones de automatización que nos servirían (Autofill y Brand Templates) están reservadas a **Canva Enterprise**, que solo se vende por cotización. Por eso generamos las imágenes por API y dejamos Canva como herramienta opcional de retoque manual. *(Verificar con Canva antes de presupuestar Enterprise.)*

- **Busi:** es un módulo interno de Lulo Studio (hoy en demo), no un proveedor externo. Su costo es solo el de los tokens del LLM: unos **$0.07 por auditoría** con Sonnet 5.5, o menos de $0.01 con Haiku 5.5.

1.5 Infraestructura de soporte

Servicio	Uso	Costo
Cloudinary	URLs públicas temporales para retratos y audio	$0 en el plan gratuito al volumen actual (verificar créditos mensuales)
Disco local	Almacenamiento de proyectos	$0
Hosting	App de escritorio / localhost	$0

2. Comparativa: modelo API vs. suscripciones SaaS directas

2.1 Escenario base (un mes típico)

Supuestos de volumen:

Partida	Volumen
Videos con avatar de 30 s	100 (= 50 minutos de Avatar IV)
Audios de locución (~500 caracteres)	500
Locución para los videos (~450 caracteres)	100
Total de caracteres TTS	295,000
Imágenes generadas	300
Guiones y copys (LLM)	600 generaciones
Mensajes del copiloto	2,000
Personas en el equipo	3

2.2 Costo vía API (pago por uso)

Partida	Cálculo	Costo
Guiones (Sonnet 5.5)	600 × $0.021	$12.60
Copiloto Mia (Gemini 3.8 Flash)	2,000 × $0.006	$12.00
TTS (Eleven v4 vía OpenRouter)	295K caracteres × $0.04/1K	$11.80
ElevenLabs Starter (clonación de voz)	Fijo	$6.00
Video con avatar (Avatar IV vía OpenRouter)	3,000 s × $0.05	$150.00
Imágenes (Nano Banana 2)	300 × ~$0.077	$23.22
Asientos adicionales	3 usuarios × $0	$0.00
Total API		**$215.62**

2.3 Costo vía suscripciones SaaS (3 usuarios)

Herramienta	Plan necesario	Por qué ese plan	Costo
ChatGPT	Business, 3 × $25/mes (mínimo 2)	Uso comercial en equipo	$75.00
ElevenLabs	Pro ($99, 600K créditos)	295K caracteres superan Creator (121K)	$99.00
HeyGen	Business ($149) + 2 asientos × $20	50 min × 20 créditos/min = 1,000 créditos, multiusuario	$189.00
Canva	Business, 3 × $250/año ÷ 12	Imágenes y plantillas (créditos de IA incluidos)	$62.50
Total SaaS			**$425.50**

> **Supuestos favorables al SaaS:** comparamos contra ChatGPT Business y no contra Claude Team, que exige mínimo 5 asientos ($125/mes). En ElevenLabs suponemos una sola cuenta Pro compartida; con asientos individuales haría falta Scale ($299, 3 asientos), y el total SaaS subiría a **$625.50**. También suponemos que los créditos de IA de Canva alcanzan para las 300 imágenes.

2.4 Resultado del escenario base

	SaaS	API	Diferencia
Mensual	$425.50	$215.62	**−$209.88 (−49 %)**
Anualizado	$5,106	$2,587	**−$2,519**

2.5 Sensibilidad por volumen

Partida	Mes bajo (API)	Mes base (API)	Mes pico (API)
Videos de 30 s / audios / imágenes	20 / 100 / 60	100 / 500 / 300	300 / 1,500 / 900
LLM (guiones + copiloto)	$4.92	$24.60	$73.80
TTS + Starter	$8.36	$17.80	$41.40
Video Avatar IV	$30.00	$150.00	$450.00
Imágenes	$4.64	$23.22	$69.66
Total API	**$47.92**	**$215.62**	**$634.86**
Total SaaS	**$348.50**	**$425.50**	**$700.50**

En el mes bajo, el SaaS baja ElevenLabs a Creator ($22). En el pico sube a Scale ($299) y compra 5 paquetes de créditos de HeyGen ($75).

Escalamiento por equipo: si el equipo pasa de 3 a 6 personas, el stack SaaS sube unos **$197/mes** (ChatGPT +$75, HeyGen +$60, Canva +$62.50). El stack API sube **$0**.

3. Justificación estratégica

3.1 Eficiencia de capital: pagamos solo lo que se consume

Una suscripción es un **costo fijo disfrazado de herramienta**: se cobra igual se use al 100 % o al 5 %. En nuestro modelo, cada dólar corresponde a un artefacto producido: un segundo de video, mil caracteres de voz o un millón de tokens.

- **Mes sin producción:** el SaaS sigue facturando **$348.50**; la API factura **$6** (solo el Starter de ElevenLabs).
- **Costo unitario trazable:** la app ya calcula el costo final de cada render (`pricing.service.ts`). Esto permite fijar precio por pieza a clientes con márgenes conocidos, algo que un plan plano no permite saber.
- **Sin créditos que caducan:** los créditos de HeyGen y ElevenLabs que no se usan se pierden o solo pasan a un ciclo más. El saldo prepago de una API no caduca por ciclo.

3.2 Sin cuellos de botella por asientos

Cada herramienta SaaS cobra por persona: ChatGPT $25, HeyGen $20 por asiento extra, Canva $20.83, Claude Team con mínimo de 5 asientos. Cinco herramientas multiplicadas por N personas dan un costo que crece con la plantilla, no con la producción.

En Lulo Studio, **las claves de API viven en el servidor** (rutas `app/api/**`) y cualquier persona del equipo usa todas las capacidades desde una sola interfaz. Sumar un editor, un practicante o un freelance cuesta **$0 en licencias**. Además, se acaba el problema de compartir contraseñas de una cuenta "Pro" entre varias personas, que suele violar los términos de servicio.

3.3 Escalabilidad sin fricción

Situación	Stack SaaS	Stack API-First
Mes sin contenido	Factura completa	Factura ≈ $0
Pico de campaña (3× volumen)	Subir de plan en 2–4 apps, comprar paquetes de créditos, esperar el ciclo	La API absorbe el volumen sin cambios de configuración
Cambio de proveedor	Cancelar, migrar cuentas, perder créditos	Cambiar un ID de modelo en `ugc-models.config.ts`
Nuevo modelo más barato	Esperar a que la app lo incorpore	Disponible en OpenRouter el día de su lanzamiento

La arquitectura multiproveedor (OpenRouter + APIMart + Gemini + ElevenLabs) también nos **protege del lock-in**. Por ejemplo, podemos pasar los ganchos de prueba de Hailuo ($0.049/s) a Seedance 1.5 Pro ($0.023/s) y gastar un 53 % menos por clip, sin cambiar la experiencia del equipo.

3.4 Propiedad del flujo de trabajo: automatización y horas-persona

Con apps separadas, producir un video implica: escribir el guion en ChatGPT, copiarlo a ElevenLabs, descargar el MP3, subirlo a HeyGen junto con la foto, esperar, descargar el video, generar imágenes en Canva y organizar los archivos a mano. **Lulo Studio hace todo esto en un solo flujo:** foto → Cloudinary → TTS → render → polling → proyecto guardado en disco, con costo calculado.

Estimación de tiempo ahorrado (escenario base):

Tarea	Volumen	Minutos ahorrados por unidad*	Horas/mes
Video con avatar	100	8	13.3
Audio de locución	500	2	16.7
Imagen	300	1	5.0
Total			**~35 h**

* Supuesto interno: tiempo de copiar, pegar, descargar, subir y renombrar entre apps. Conviene validarlo midiendo una semana de trabajo real.

Con un costo de referencia de **$12 por hora-persona**, son unos **$420/mes adicionales de valor recuperado**. Sumado al ahorro directo, el beneficio total del escenario base ronda los **$630/mes**. Además, el flujo propio permite cosas que las apps separadas no ofrecen: generar variantes A/B en lote, inyectar guiones desde el copiloto, tener una biblioteca de proyectos unificada y llevar control de costos por pieza.

---

4. Dónde el SaaS compite y cómo lo manejamos

Un análisis serio debe mostrar dónde la tesis es más débil. Aquí está:

El video Avatar IV en volumen alto. En el plan web de HeyGen, Avatar IV consume 20 créditos por minuto. El plan Business incluye 1,500 créditos (75 min) por $149, y los paquetes extra cuestan $15 por 300 créditos, es decir, **~$1 por minuto marginal**. Por API, el minuto cuesta **$3** (vía OpenRouter).

- **Punto de equilibrio:** con un equipo de 3 personas ($189 fijos en HeyGen Business), la API es más barata **por debajo de ~63 minutos de avatar al mes** (unos 126 videos de 30 s). Por encima de ese volumen, el plan web gana en ese rubro específico.
- **Límite del plan web:** sus créditos no se pueden consumir desde nuestra app por API directa (la API usa un saldo aparte). Habría que volver al flujo manual, con lo que se pierden las ~13 h/mes de automatización del video.

Estrategia recomendada:

1. **Mantener API-First por defecto.** Incluso en el mes pico, el stack completo sigue siendo más barato ($634.86 frente a $700.50).
2. **Revisar el umbral cada trimestre:** si el volumen sostenido supera ~150 minutos de avatar al mes, negociar con HeyGen **Enterprise API** (incluye "discounted rates") en lugar de pasar al plan web.
3. **Mover los clips que no necesitan lip-sync a modelos más baratos** (Seedance 1.5 Pro a $0.023/s, Wan 2.6 a $0.04/s), y reservar Avatar IV para los voceros que hablan a cámara.

---

5. Recomendaciones FinOps accionables

#	Acción	Impacto estimado
1	Migrar el TTS por defecto de Multilingual v2 (directa, $0.08/1K) a **Eleven v4 vía OpenRouter ($0.04/1K)**	−50 % en voz
2	Migrar el flujo UGC y `heygen.service.ts` de la API directa de HeyGen ($0.10/s) a **OpenRouter ($0.05/s)**	−50 % en video con avatar
3	**Enrutar LLM por tarea:** Haiku 5.5 para borradores y variantes, Sonnet 5.5 solo para el guion final	−60–90 % en tokens
4	Usar **batch** (−50 %) para generaciones masivas no urgentes	−50 % en esos lotes
5	Agregar topes de presupuesto mensual por proveedor y alertas en `pricing.service.ts`	Evita sorpresas
6	Quitar los fallbacks de assets falsos (`ugc-dispatcher`) y el mock silencioso de `openrouter-video.service.ts`	Evita gastar créditos en renders inválidos
7	Reemplazar los créditos fijos de la UI (`2450`) por el saldo real de cada proveedor	Visibilidad del gasto

6. Metodología y supuestos

- Los precios se tomaron el 10/10/2026 de las páginas oficiales de precios de OpenRouter, ElevenLabs, HeyGen y Canva. Para los planes de ChatGPT y Claude se usó un comparativo de terceros (junio de 2026), que debe validarse en los sitios oficiales antes de comprar.
- Los precios de APIMart y de los modelos de video secundarios vienen del catálogo interno `src/config/ugc-models.config.ts`, que se sincroniza con tarifas en vivo de OpenRouter.
- Los precios de IA bajan con frecuencia. **Recomendamos recalcular este análisis cada trimestre.** Los volúmenes del escenario son ilustrativos y deben reemplazarse por la telemetría real de la app.
- Las cifras de tokens por operación, caracteres por audio y minutos ahorrados son supuestos de planificación, no mediciones.
- Este documento es un análisis operativo, no asesoría financiera ni contable.

Fuentes

- OpenRouter — modelos de Anthropic
- OpenRouter — modelos de Google
- OpenRouter — HeyGen Avatar IV
- OpenRouter — catálogo de modelos (Eleven v4)
- ElevenLabs — precios de la API
- ElevenLabs — planes
- HeyGen — precios de la API (developers)
- HeyGen — precios de la API
- HeyGen — planes web
- Arcade — HeyGen pricing 2026 (créditos de Avatar IV)
- Creatify — HeyGen pricing 2026
- Canva — precios
- Morph — ChatGPT vs Claude pricing 2026